

Nedensel Öğrenme (Causal Learning)

Saffet Gökçen Şen

EE Müh. Böl., ETÜ.

December 27, 2021

İçerik

- 1 Nedensel öğrenmenin tanımı ve nedensel model
 - Nedensel öğrenmenin tanımı
 - Nedensel model ve bileşenleri
 - Nedensel model
 - Nedensel model bileşenleri
- 2 Simpson Paradoksu
- 3 Araya girme (intervention)
- 4 Etki karışımı (confounding)
- 5 Karşıolgusallar (Counterfactuals)
- 6 Ayırtedilebilirlik (Identifiability)
- 7 Nedensel modelin giriş özelliklerine (features) etkisi
- 8 Referanslar

Nedensel öğrenmenin tanımı

Nedensel öğrenme, nedensel bir model ve eldeki veriye dayanılarak gerçekleştirilen bir öğrenme çeşitidir.

Nedensel model

Nedensel model (causal model), özellikler (features) veya değişkenler (variables) arasındaki nedensellik ilişkisini ortaya koyan bir modeldir. Nedensel model, eldeki verinin arkasındaki nedensel hikayeyi anlatır. Eldeki veriyi üreten nedensel mekanizmalar hakkında bilgi verir. Özelliklerimiz X , Y ve Z olsun. Aşağıdaki denklemler, bir nedensel model tanımlar:

$$\begin{aligned}X &= f_X(U_X) \\Y &= f_Y(X, U_Y) \\Z &= f_Z(X, Y, U_Z)\end{aligned}\tag{1}$$

Bu denklemleri incelediğimizde, X 'in nedeninin ya ihmal edilip çözümlemeye dahil edilmediğini ya da bilinmediğini, Y 'nin nedeninin X olduğunu ve Z 'nin nedenlerinin de X ve Y olduğunu belirleriz.

Nedensel model

Bir nedensel model nasıl oluşturulur? Akıl ve mantık kuralları kullanılarak, günlük tecrübelerle dayanılarak, bilimsel literatüre dayanılarak, çalışılan alana ait bilgi birikimine (domain knowledge) dayanılarak, alanın bir uzmanına dayanılarak (expert knowledge) nedensel modeller oluşturulabilir.

Nedensel model bileşenleri

Model içi değişkenler

(1) denkleminde verilen model üzerinden bir nedensel modelin bileşenlerini belirtelim.

$\{X, Y, Z\}$ kümesindeki özellikler, model içi (endogenous) özelliklerdir. Elimizdeki veri, bu özelliklere aittir.

Bir problemdeki (bazı) özellikler arasında nedensellik ilişkileri yoksa bu (bazı) özellikler kullanılarak aralarında nedensellik ilişkileri bulunan yeni özellikler yaratılabilir. Bu işleme nedensel özellik öğrenme (causal feature learning) adı verilir.

Nedensel model bileşenleri

Model dışı değişkenler

$\{U_X, U_Y, U_Z\}$ kümesindeki elemanlar, model dışı (exogenous) değişkenlerdir. Bu değişkenler, hakkında bilgi sahibi olmadığımız nedenlerin modele katılmamasından kaynaklanan hataları temsil edebilirler. Özellikler arasındaki nedensellik ilişkisini temsil eden fonksiyonların belirlenmesindeki hataları temsil edebilirler. Hakkında bilgi sahibi olduğumuz ama modellemeye katmak istemediğimiz özellikler de bu değişkenler ile temsil edilebilir. Genel olarak model dışı değişkenlerin birbirlerinden bağımsız oldukları varsayılır.

Nedensel model bileşenleri

Fonksiyonlar

$\{f_X, f_Y, f_Z\}$ kümesindeki fonksiyonlar, özellikler arasındaki nedensellik ilişkilerini matematiksel olarak ifade ederler. Bu fonksiyonların temsil ettiği mekanizmalar otonomdur. Yani, mekanizmaların birisinde meydana gelen değişiklik diğer mekanizmalarda bir değişikliğe neden olmaz. Otonomluk özelliği, nedensel modeller için çok önemlidir. Bu özellik sayesinde araya girme (intervention), karşıolgusal (counterfactual) gibi kavramlar tanımlanabilir. Ayrıca, bir nedensel model ile bir veri kümesinin arasındaki uyumu sınarken modelde yerel güncellemeler yapılabilmesi açısından da çok faydalı bir özelliktir.

Nedensel model bileşenleri

Grafik

Grafikler, nedensel öğrenme için vazgeçilmez araçlardır. Nedensel modellerin grafikleri genellikle çevrimsiz (acyclic) olur. Bu grafiklere yönlü çevrimsiz grafikler (directed acyclic graphs) (DAGs) adı verilir. (1) denkleminde verilen örnek nedensel modelin grafiği Figure (1) şeklinde gösteriliyor.




Figure 1: (1) denkleminde verilen modelin DAG'ı.

Simpson Paradoksu

Bir okulda sigara içen öğrenciler ile sigara içmeyen öğrencilerin ortalama sınav notunu karşılaştırdınca sigara içenlerin ortalamasının daha yüksek olduğu görülüyor. Daha sonra yaş özelliği de değerlendirmenin içine alınıyor. Eldeki veri, yaş özelliğine göre gruplara ayrılıyor. Yaşın sabit olduğu her bir grup içinde sigara içmeyen öğrencilerin ortalamasının sigara içen öğrencilerinkinden yüksek olduğu belirleniyor. Sigaranın başarıya olan etkisi tersine döndü. Gelir özelliğini de değerlendirmeye alıyoruz. Veriyi yaşa ve gelir düzeyine göre gruplara ayırıyoruz. Yaşın ve gelir düzeyinin sabit olduğu gruplar içinde sigara içen öğrencilerin ortalamasının içmeyenlerinkinden yüksek olduğunu belirliyoruz. Sigaranın başarıya olan etkisi yine tersine döndü. Meydana gelen bu tersine dönmelere Simpson paradoksu adı veriliyor.

Simpson Paradoksu

Ne yapacağız peki? Sigaranın başarıya olan etkisini nasıl belirleyeceğiz? Sigaranın başarıya olan etkisi hakkında ne söyleyeceğiz? Sigara ile ilgili nasıl bir eylem planı belirleyeceğiz?

Sadece veriye dayanarak bu sorulara cevap vermek imkansızdır!!!
Bütün bu soruları tutarlı, güvenilir ve kararlı bir şekilde cevaplayabilmek için nedensel bir modele ihtiyaç var!!!

Araya girme (intervention)

Bir özelliğin başka bir özelliğe nedensel etkisini belirlemenin ölçün (standart) yöntemi rastgele denetimli deneydir (randomized controlled trial). Rastgele denetimli deneyde, etkilenen özellik ve etkisi belirlenmek istenen özellik dışındaki bütün özellikler ya sabit tutulur ya da tamamen rastgele değiştirilirler. Etkisi belirlenmek istenen özellik ise değiştirilir.

Rastgele denetimli deney yapmadan, elimizdeki veriyi kullanarak nedensel etkiyi belirleyebilir miyiz? Bir nedensel modelimiz varsa, evet, belirleyebiliriz. Araya girme (intervention) ve "do calculus" ile sadece elimizdeki veriyi kullanarak nedensel etki belirlenebilir.

Etki karışımı (confounding)

Bir özelliğin başka bir özellik üzerindeki nedensel etkisini belirlerken gerçekte ölçmek istediğimiz ile ölçtüğümüz arasında bir fark olmasına etki karışımı adı verilir. Etki karışımından kaçınmak ve bir özelliğin başka bir özellik üzerindeki nedensel etkisini doğru belirleyebilmek için ne yapmak gerekir? Herşeyden önce bir nedensel modele ihtiyaç vardır. Arka kapı ölçütü (back-door criterion) yardımıyla etki karışımının olup olmayacağı, etki karışımı varsa hangi özellik veya özelliklere koşul koyularak giderilebileceği ve gerçek etkinin değeri belirlenebilir. Arka kapı ölçütü, nedensel öğrenmeye ait bir kavramdır. Arka kapı ölçütünün ele alamadığı bazı durumlar ön kapı ölçütü (frontdoor criterion) ile çözülebilir. Her iki ölçütün kullanımında araya girme (intervention) uygulanır.

Karşılgusallar (Counterfactuals)

Makine öğrenmesinin hemen hemen her zaman peşinde olduğu şey belli giriş özellikleri için çıkışın ne olduğu, yani tahmindir. Bunun nedensel öğrenmedeki benzeri karşılgusallardır. Makine öğrenmesindeki tahmin ile nedensel öğrenmedeki karşılgusal aynı değildir.

Tahmin: $t = t_0$ anında akım I_0 ve voltaj V_0 iken, diğer bütün şeyler aynı iken (ceteris paribus), $t > t_0$ için t anındaki voltaj aşağıdaki gibi olacaktır:

$$V(t) = \frac{V_0}{I_0} I(t) \quad (2)$$

Karşılgusal: $t = t_0$ anında akım I_0 ve voltaj V_0 iken, $t = t_0$ anındaki akım I' olsaydı, $t = t_0$ anındaki voltaj

$$V' = \frac{V_0}{I_0} I' \quad (3)$$

olacaktı.

Karşılgusallar

Makine öğrenmesinin tahmininde "diğer şeyler aynı olmak üzere" koşulu var. Burada bir belirsizlik var. Diğer şeyler nedir? Nedensel öğrenmenin karşılgusalında ise bir belirsizlik yok. Koşullar, $t = t_0$ anındaki koşullar veya koşullar, kullanılan nedensel modelin gerektirdiği koşullar. Yani, karşılgusal, iyi tanımlanmış koşullar altında tahminler bildiren bir kavramdır.

Ayırtedilebilirlik (Identifiability)

Makine öğrenmesinde bulunmak istenen büyüklükler, eldeki özelliklerin birleşik olasılık dağılımına (joint probability distribution) göre tanımlanır. Bu büyüklükler, istatistiksel büyüklüklerdir. Makine öğrenmesinde sadece eldeki veriye dayanılarak işlem yapılır. Birbirlerinden farklı modeller aynı birleşik olasılık dağılımını verebilirler. Dolayısıyla, birleşik olasılık dağılımına bağlı olan istenen büyüklük doğru bir şekilde elde edilemeyebilir. Ne kadar veri olursa olsun (big data) durum değişmez. Bu büyüklük, ayırtedilebilirlik sorununa sahiptir.

Ayırtedilebilirlik

Nedensel öğrenmede ise istatistiksel büyüklüklerin değil nedensel büyüklüklerin peşine düşülür. Nedensel büyüklükler, eldeki verinin birleşik olasılık dağılımına göre değil verinin arkasındaki nedensel modele göre tanımlanırlar. Nedensel etki (causal effect), bir nedensel büyüklüktür. Nedensel etki, ayırtedilebilir bir büyüklüktür. M_1 ve M_2 , aynı özellik (feature) kümesine sahip iki farklı nedensel model olsun. Bu modellerin DAG'ları ve birleşik olasılık dağılımları aynı ise X özelliğinin Y özelliğine nedensel etkisi iki modelde de aynı çıkacaktır.

Nedensel modelin giriş özelliklerine (features) etkisi

Nedensel modelimizin DAG'ı Figure 2 şeklindeki gibi olsun.




Figure 2

Bu nedensel modelin ürettiği veriye

$$Y = a + bX + cV \quad (4)$$

$$Y = a + bX + cT \quad (5)$$

regresyon eğrilerini uydurduğumuzda b 'nin sıfırdan farklı çıkmasını beklemek ne kadar anlamlıdır?

Nedensel modelin giriş özelliklerine etkisi

Figure (2) şeklindeki nedensel model, Y ile X özelliklerinin birbirlerinden koşulsuz olarak bağımsız olduklarını söyler. Ayrıca, Y ve X özellikleri V koşullu olarak da birbirlerinden bağımsızdırlar. Dolayısıyla, (4) denklemindeki eğriyi veriye uydurduğumuzda $b \neq 0$ olması beklenmemelidir. Ama, Y ve X özellikleri T koşullu bağımlıdırlar. Dolayısıyla, (5) denklemindeki eğriyi veriye uydurduğumuzda $b = 0$ olması beklenmemelidir.

Referanslar

Nedensel öğrenme ile ilgili aşağıdaki kitapları okumaktayım. Sunuşu hazırlarken de bu okumalardan elde ettiğim birikimi kullandım.

Judea Pearl, *Causality Models, Reasoning, and Inference*, Cambridge University Press.

Judea Pearl, Madelyn Glymour, Nicholas P. Jewell, *Causal Inference in Statistics a Primer*, Wiley & Sons Ltd.

Judea Pearl, Dana Mackenzie, *The Book of Why: The New Science of Cause and Effect*, Basic Books.